ĐẠI HỌC KINH TẾ QUỐC DÂN

KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO MÔN HỌC

XỬ LÝ ẢNH

ĐỀ TÀI

PHÂN TÍCH, PHÁT HIỆN DẤU HIỆU CHỈNH SỬA VÀ TRÍCH XUẤT DỮ LIỆU TỰ ĐỘNG TỪ GIẤY CHỨNG NHẬN QUYỀN SỬ DỤNG ĐẤT

Giảng viên hướng dẫn : Phạm Minh Hoàn
Nhóm thực hiện : Nhóm 4
Thành viên : Hoàng Thành Công - 11236201
: Ma Tùng Sơn - 11243801
: Mai Mạnh Duy - 11211679
: Nguyễn Ngô Minh Đức - 11243759
: Vũ Tiến Đạt - 11221281

Hà Nội, 2026

Mục lục

Đánh giá đóng góp thành viên 1

Tóm tắt 2

1 GIỚI THIỆU 3
- 1.1 Bối cảnh . . . 3
- 1.2 Mục tiêu . . . 3
- 1.3 Phạm vi . . . 3

2 DỮ LIỆU VÀ TIỀN XỬ LÝ 4
- 2.1 Tập dữ liệu . . . 4
- 2.2 Tiền xử lý . . . 4
- 2.3 Phân vùng ROI . . . 5

3 PHƯƠNG PHÁP 5
- 3.1 Kiến trúc tổng thể . . . 5
- 3.2 Hough Transform và Skeletonization . . . 6
- 3.3 HSV và phân tích con dấu . . . 7
- 3.4 FFT . . . 7
- 3.5 Các tín hiệu của Diagram Tamper . . . 7
- 3.6 Tổng hợp điểm Diagram Tamper . . . 8
- 3.7 Text Tamper . . . 8
- 3.8 OCR và trích xuất thông tin . . . 8

4 THỰC NGHIỆM VÀ KẾT QUẢ 9
- 4.1 Nguyên tắc đánh giá . . . 9
- 4.2 Đánh giá phát hiện Text Tamper . . . 9
- 4.3 Đánh giá OCR . . . 11
- 4.4 Đánh giá Geometry . . . 12

5 PHẦN MỀM MINH HỌA 13
- 5.1 Môi trường . . . 13
- 5.2 Trang 2 – OCR và Text Tamper . . . 13

5.3 Trang 3 – Diagram Tamper và Seal Tamper 15
5.4 Batch và xuất dữ liệu 18

6 THẢO LUẬN 20
6.1 Hạn chế 20
6.2 Cách diễn giải kết quả 20

7 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 20
7.1 Kết luận 20
7.2 Hướng phát triển 21

Tài liệu tham khảo 22

A CẤU TRÚC MÃ NGUỒN 23

B CÁC FILE KẾT QUẢ CHÍNH 23

Danh sách bảng

1 Cách tính điểm đóng góp 1
2 Đánh giá đóng góp của các thành viên 2
3 Thống kê dữ liệu thực nghiệm 4
4 Các vùng quan tâm trong pipeline 5
5 Ma trận nhầm lẫn của benchmark Real/Text Tamper 9
6 Kết quả benchmark phát hiện chỉnh sửa 10
7 Kết quả PaddleOCR trên controlled synthetic benchmark 12
8 Kết quả benchmark Geometry 12
9 Các file chính của project 23

Danh sách hình vẽ

1 Sơ đồ khối của hệ thống 6
2 Đường cong ROC của benchmark phát hiện chỉnh sửa 10
3 Confusion Matrix xuất từ chương trình Tuần 5 11
4 Kết quả OCR và Text Tamper trên Trang 2. 14
5 Kết quả kiểm tra Diagram Tamper. 16
6 Kết quả kiểm tra Seal Tamper. 17
7 Kết quả xử lý batch và xuất dữ liệu. 19

ĐÁNH GIÁ ĐÓNG GÓP THÀNH VIÊN

Nhóm sử dụng mức 8.0 làm điểm cơ sở khi thành viên hoàn thành phần việc được giao ở mức đạt yêu cầu. Điểm cộng được xét theo kiểm thử, chất lượng sản phẩm, hỗ trợ công việc chung và trách nhiệm nhóm trưởng.

Bảng 1: Cách tính điểm đóng góp

Tiêu chí	Mức điểm	Cách tính
Điểm cơ sở	8.00	Hoàn thành phần việc được giao ở mức đạt yêu cầu.
Kiểm thử	Tối đa +0.50	+0.25 cho mỗi lần kiểm thử và gửi lại kết quả; tối đa hai lần.
Chất lượng sản phẩm	Tối đa +0.50	Xét mức độ hoàn thiện và khối lượng phải chỉnh sửa lại.
Hỗ trợ công việc chung	Tối đa +0.50	Tính cho phần hỗ trợ ngoài nhiệm vụ chính.
Nhóm trưởng	+0.50	Điều phối tiến độ, tích hợp sản phẩm và xử lý công việc chung.

Bảng 2: Đánh giá đóng góp của các thành viên

Thành viên	Vai trò	Điểm	Nhận xét
Vũ Tiến Đạt	Nhóm trưởng / Lead Developer	9.50	Phụ trách chính phần code và tích hợp hệ thống, xử lý phần lớn lỗi phát sinh; đồng thời hỗ trợ hoàn thiện báo cáo Overleaf và chỉnh sửa slide.
Nguyễn Ngô Minh Đức	Sub Developer	8.75	Hoàn thành phần phát triển được giao với chất lượng tốt; tham gia một lần kiểm thử code và gửi lại kết quả.
Ma Tùng Sơn	Phụ trách slide	8.75	Hoàn thành đủ hai lần kiểm thử code và có hỗ trợ chỉnh sửa slide; bản ban đầu vẫn cần chỉnh thêm trước khi chốt.
Hoàng Thành Công	Tester	8.50	Hoàn thành phần việc ở mức đạt yêu cầu và thực hiện đủ hai lần kiểm thử code.
Mai Mạnh Duy	Phụ trách báo cáo	8.00	Hoàn thành phần báo cáo ở mức đạt yêu cầu; chưa hoàn thành hai lần kiểm thử code theo kế hoạch chung.

TÓM TẮT

Đề tài xây dựng hệ thống hỗ trợ trích xuất thông tin và phát hiện một số dấu hiệu chỉnh sửa trên ảnh Giấy chứng nhận quyền sử dụng đất. Pipeline gồm tiền xử lý ảnh, tách ROI, OCR và các nhánh phân tích Text Tamper, Diagram Tamper và Seal Tamper. Các kỹ thuật chính gồm Canny Edge Detection, Perspective Transform, Hough Transform, CLAHE, HSV, FFT, Local Binary Pattern (LBP) và Morphological Skeletonization.

Tesseract được dùng làm OCR baseline ở Tuần 3; pipeline chính từ Tuần 4 sử dụng PaddleOCR. Phiên bản tích hợp cuối kiểm tra Text Tamper theo các trường OCR, Diagram Tamper bằng local anomaly, rectangular paste, copy-move và seam, còn vùng con dấu được phân tích bằng HSV và LBP.

Bộ dữ liệu gồm 78 ảnh nguồn. Sau bước ẩn thông tin cá nhân khi cần, 78 ảnh được lưu thành tập Real; từ đó nhóm tạo 31 Text Tamper, 78 Diagram Tamper và 59 Seal Tamper theo cách synthetic có kiểm soát.

Benchmark Real/Text Tamper của Tuần 5 đạt Accuracy 69.72%, Recall 67.74%, F1-score 56.00% và AUC-ROC 72.75%. PaddleOCR đạt CER = 0%, WER = 0% và

Exact Match = 100% trên 30 ảnh synthetic có kiểm soát; Geometry benchmark trên 40 ảnh đường thẳng đạt Line Detection Rate 100% và MAPE 13.56%.

Ứng dụng cuối được xây dựng bằng Streamlit và hỗ trợ xuất JSON/Excel. Các TamperScore chỉ là chỉ số bất thường phục vụ sàng lọc, không phải xác suất giả mạo hay kết luận pháp lý.

Từ khóa: xử lý ảnh số, document tampering, OCR, Hough Transform, HSV, FFT, LBP, PaddleOCR.

1 GIỚI THIỆU

1.1 Bối cảnh

Ảnh chụp hoặc ảnh quét giấy chứng nhận có thể bị lệch góc, mờ, thiếu sáng hoặc nén mạnh. Những yếu tố này làm OCR khó hơn và cũng có thể tạo tín hiệu dễ nhầm với chỉnh sửa ảnh. Bên cạnh đó, các nội dung như diện tích, số thửa, tờ bản đồ, sơ đồ hoặc con dấu có thể bị can thiệp bằng phần mềm chỉnh sửa.

Vì vậy, đề tài kết hợp hai nhiệm vụ: trích xuất thông tin và cảnh báo các vùng có dấu hiệu bất thường để hỗ trợ bước kiểm tra ban đầu. Hệ thống chỉ phân tích ảnh số và không thay thế việc đối chiếu hồ sơ gốc hay giám định tài liệu.

1.2 Mục tiêu

1. Chuẩn hóa ảnh và tách ROI cho text, diagram và seal.
2. Áp dụng các kỹ thuật xử lý ảnh phù hợp cho từng vùng.
3. Xây dựng pipeline OCR và trích xuất các trường thông tin chính.
4. Xây dựng các nhánh Text Tamper, Diagram Tamper và Seal Tamper.
5. Đánh giá một số thành phần bằng benchmark có ground truth.
6. Tích hợp hệ thống trên Streamlit để demo.

1.3 Phạm vi

Thực nghiệm tập trung vào Trang 2 và Trang 3 vì đây là các trang phù hợp nhất với dữ liệu công khai mà nhóm thu thập được. Thông tin định danh cá nhân được che khi cần; các trường mô tả thửa đất được giữ lại cho OCR và phân tích.

Dữ liệu Tampered trong báo cáo là synthetic tamper tạo từ ảnh Real. Do đó, kết quả định lượng chỉ được diễn giải trong phạm vi bộ kiểm thử hiện tại.

2 DỮ LIỆU VÀ TIỀN XỬ LÝ

2.1 Tập dữ liệu

Nhóm sử dụng 78 ảnh nguồn. Sau khi che thông tin cá nhân khi cần, các ảnh được lưu thành tập Real. Từ tập này, nhóm tạo thêm các biến thể synthetic để kiểm thử thuật toán.

Bảng 3: Thống kê dữ liệu thực nghiệm

Nhóm dữ liệu	Số ảnh	Mô tả
Real	78	Ảnh sau bước ẩn thông tin cá nhân khi cần.
Text Tamper	31	Thay đổi giá trị ở Diện tích, Số thửa hoặc Tờ bản đồ.
Diagram Tamper	78	Ngắt nét, thêm đường song song hoặc thêm đoạn ngắn.
Seal Tamper	59	Xóa một phần, làm mờ cục bộ hoặc làm nhạt màu đỏ của dấu.

Tổng cộng có 246 file Real/Tampered, nhưng chỉ có 78 ảnh nguồn độc lập. Thông tin source_index được giữ lại để các biến thể từ cùng một nguồn không bị tách sang hai phía khác nhau khi đánh giá mô hình.

Các vùng PII như họ tên, địa chỉ cư trú và CMND/CCCD được che bằng mosaic/pixelation. Các trường phục vụ bài toán như Số thửa, Tờ bản đồ, Diện tích và thông tin sử dụng đất được giữ lại.

2.2 Tiền xử lý

Quy trình tiền xử lý của nhóm gồm:

1. Sử dụng Edge Detection để hỗ trợ xác định biên và đường bao của tài liệu.
2. Nếu tìm được bốn góc phù hợp, áp dụng Perspective Transform để làm phẳng trang.

3. Nếu không tìm được bốn góc, sử dụng Hough Transform để ước lượng góc nghiêng và xoay ảnh.
4. Chuẩn hóa kích thước ảnh về 1200×800 pixel.
5. Chuyển ảnh sang mức xám và tăng tương phản cục bộ bằng CLAHE.
6. Tách các ROI phục vụ xử lý text, diagram, seal và ảnh toàn trang.

Canny Edge Detection được sử dụng để hỗ trợ tìm biên [1].

Hough Transform được sử dụng để phát hiện đường thẳng và hỗ trợ ước lượng góc nghiêng [2, 8].

2.3 Phân vùng ROI

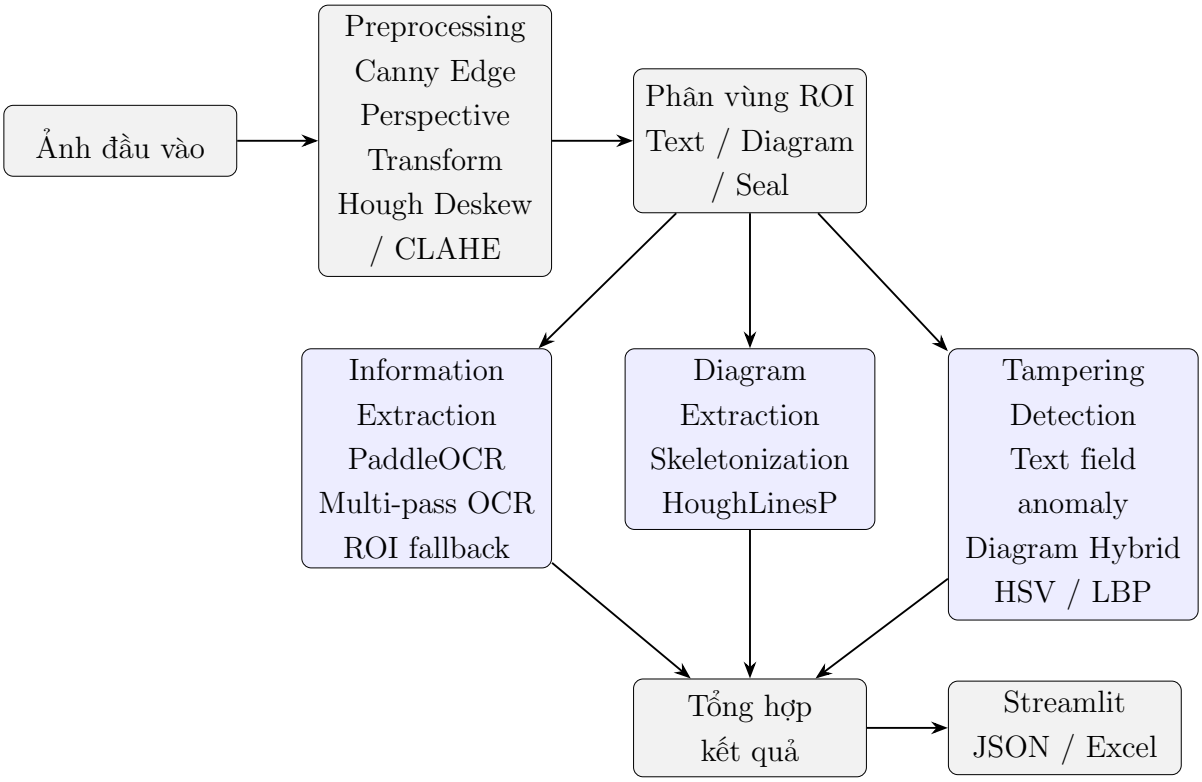
Bảng 4: Các vùng quan tâm trong pipeline

ROI	Mục đích	Kỹ thuật chính
Text	OCR và kiểm tra chỉnh sửa chữ/số	PaddleOCR, định vị trường, bất thường mức xám và tín hiệu màu
Diagram	Trích xuất đường nét và kiểm tra chỉnh sửa	Hough/Skeletonization, Diagram Hybrid
Seal	Phân tích vùng con dấu	HSV, LBP
Full CLAHE	Phân tích toàn ảnh và benchmark	FFT và đặc trưng thống kê

3 PHƯƠNG PHÁP

3.1 Kiến trúc tổng thể

Hình 1 trình bày luồng chính của hệ thống theo ba nhóm chức năng: tiền xử lý, phân tích dấu hiệu chỉnh sửa và trích xuất thông tin/sơ đồ.



Hình 1: Sơ đồ khối của hệ thống

Sơ đồ tách rõ phần trích xuất thông tin và phần kiểm tra bất thường. Hough/Skeletonization được dùng cho đường nét sơ đồ; detector Diagram dùng các tín hiệu Hybrid; detector Text làm việc theo các trường OCR; nhánh Seal dùng HSV và LBP.

3.2 Hough Transform và Skeletonization

Đường thẳng trong Hough Transform được biểu diễn bởi:

$$\rho = x\cos\theta + y\sin\theta. \tag{1}$$

Trong hệ thống, Hough được dùng cho hai việc: ước lượng góc nghiêng khi preprocessing và trích xuất đoạn thẳng trong ROI sơ đồ [2, 8]. Trước HoughLinesP, ảnh nhị phân được làm mỏng bằng Morphological Skeletonization để đưa nét về gần dạng đường xương.

Tuần 4 sử dụng các đặc trưng như số đoạn, số nét ngắn/dài và tổng độ dài để so sánh Real/Tampered. Ở Tuần 7, Hough/Skeletonization còn tạo Geometry Locator để khoanh vùng đường nét đáng chú ý và hỗ trợ heatmap. Điểm Geometry Locator chỉ dùng cho trực quan hóa, không cộng trực tiếp vào Diagram TamperScore.

3.3 HSV và phân tích con dấu

HSV được dùng để tách các vùng đỏ có khả năng là con dấu. Sau khi xác định ROI seal, chương trình tính histogram LBP để mô tả kết cấu cục bộ [3]. Ở Tuần 7, histogram của ảnh kiểm tra được so sánh với mẫu tham chiếu tạo từ các ảnh Real bằng khoảng cách Bhattacharyya; median và MAD được dùng để xác định ngưỡng tham chiếu.

Điểm Seal kết hợp độ lệch LBP và tỷ lệ pixel đỏ:

$$S_{\text{seal}} = 0.72S_{\text{LBP}} + 0.28S_{\text{color}}. \tag{2}$$

Nếu không tìm thấy vùng dấu đủ rõ hoặc chưa có đủ mẫu Real tham chiếu, nhánh Seal trả về trạng thái thiếu dữ liệu thay vì tự kết luận chỉnh sửa.

3.4 FFT

FFT chuyển ảnh sang miền tần số; trong project, tỷ lệ năng lượng tần số cao được dùng như một đặc trưng hỗ trợ cho thay đổi biên/kết cấu [4]. FFT xuất hiện ở baseline Tuần 3 và trong đặc trưng patch của detector, nhưng không được dùng riêng để kết luận chỉnh sửa.

3.5 Các tín hiệu của Diagram Tamper

Diagram Tamper kết hợp bốn tín hiệu:

- Local anomaly: đặc trưng patch gồm độ lệch chuẩn, entropy, mật độ biên, Laplacian variance và FFT.
- Rectangular paste: tìm vùng gần hình chữ nhật có biên hoặc kết cấu khác khu vực xung quanh.
- Copy-move: dùng SIFT, với ORB làm phương án dự phòng, để tìm các cặp đặc trưng có dịch chuyển nhất quán [5, 6].
- Seam: đo bất liên tục cường độ/kết cấu ở các đường nối.

Blur mask được dùng để giảm ảnh hưởng của các vùng đã che thông tin cá nhân.

3.6 Tổng hợp điểm Diagram Tamper

$$S_{\text{diagram}} = 0.34S_{\text{local}} + 0.28S_{\text{paste}} + 0.28S_{\text{copy}} + 0.10S_{\text{seam}}. \tag{3}$$

Ba mức hiển thị là: dưới 0.40 – chưa phát hiện chỉnh sửa; từ 0.40 đến dưới 0.62 – cần kiểm tra; từ 0.62 trở lên – nghi vấn chỉnh sửa. Chương trình có thêm override khi rectangular paste hoặc copy-move cho tín hiệu rất mạnh. Các ngưỡng này là ngưỡng kỹ thuật của demo, không phải xác suất giả mạo.

3.7 Text Tamper

Detector Text ở bản cuối tập trung vào ba trường: Số thửa, Tờ bản đồ và Diện tích. Sau khi OCR định vị trường, chương trình so sánh vùng giá trị với vùng lân cận bằng các tín hiệu mức xám (Laplacian, halo, tỷ lệ pixel tối) và một tín hiệu màu bổ sung cho dữ liệu synthetic.

Với mỗi trường f:

$$S_f = \max\left(S_{f,\text{gray}}, S_{f,\text{color}}\right), \qquad S_{\text{text}} = \max_{f \in \mathcal{F}} S_f. \tag{4}$$

Nếu điểm theo trường thấp, chương trình còn có fallback tìm cue màu synthetic trên vùng text và chỉ gán về trường gần nhất khi vị trí phù hợp.

Ngưỡng trạng thái là 0.40 và 0.62. Khi điểm dưới 0.40, hệ thống chỉ trả về trạng thái bình thường nếu OCR đọc và detector định vị được ít nhất hai trong ba trường lõi; nếu không, kết quả là "Cần kiểm tra". Overlay chỉ dùng để đánh dấu trường nghi vấn và không làm thay đổi TamperScore.

3.8 OCR và trích xuất thông tin

Tesseract được dùng làm baseline ở Tuần 3. Từ Tuần 4, nhóm sử dụng PaddleOCR cho pipeline chính và giữ cách triển khai này ở ứng dụng cuối.

Luồng OCR Trang 2 gồm:

1. chạy PaddleOCR trên ảnh và các biến thể tăng cường;
2. chuẩn hóa văn bản và nhãn trường;
3. dùng ROI fallback khi trường còn thiếu hoặc chưa hợp lệ;
4. kiểm tra ứng viên bằng regex và ngữ cảnh;

5. trả về các trường dữ liệu có cấu trúc.

Các trường chính gồm Số thửa, Tờ bản đồ, Địa chỉ thửa đất, Diện tích, Hình thức sử dụng, Mục đích sử dụng, Thời hạn sử dụng và Nguồn gốc sử dụng. Trường không đủ căn cứ OCR được để trống thay vì tự suy ra [7, 9].

4 THỰC NGHIỆM VÀ KẾT QUẢ

4.1 Nguyên tắc đánh giá

Các chỉ số được lấy từ kết quả chạy chương trình. Với các biến thể sinh từ cùng một ảnh, source_index được dùng để hạn chế data leakage.

Cần phân biệt benchmark Tuần 5 với ứng dụng Tuần 7. Tuần 5 cung cấp số liệu định lượng cho Real/Text Tamper, OCR synthetic và Geometry. Tuần 7 là bản tích hợp phục vụ demo và đã thay đổi thuật toán Text Tamper; vì vậy Accuracy và AUC của Tuần 5 không được xem là độ chính xác của detector Text ở bản cuối.

4.2 Đánh giá phát hiện Text Tamper

Benchmark Tuần 5 sử dụng 109 mẫu, gồm 78 Real và 31 Text Tamper.

Mô hình đánh giá sử dụng tập đặc trưng ảnh kết hợp StandardScaler và Logistic Regression. Dự đoán được thực hiện bằng grouped out-of-fold cross-validation theo source_index.

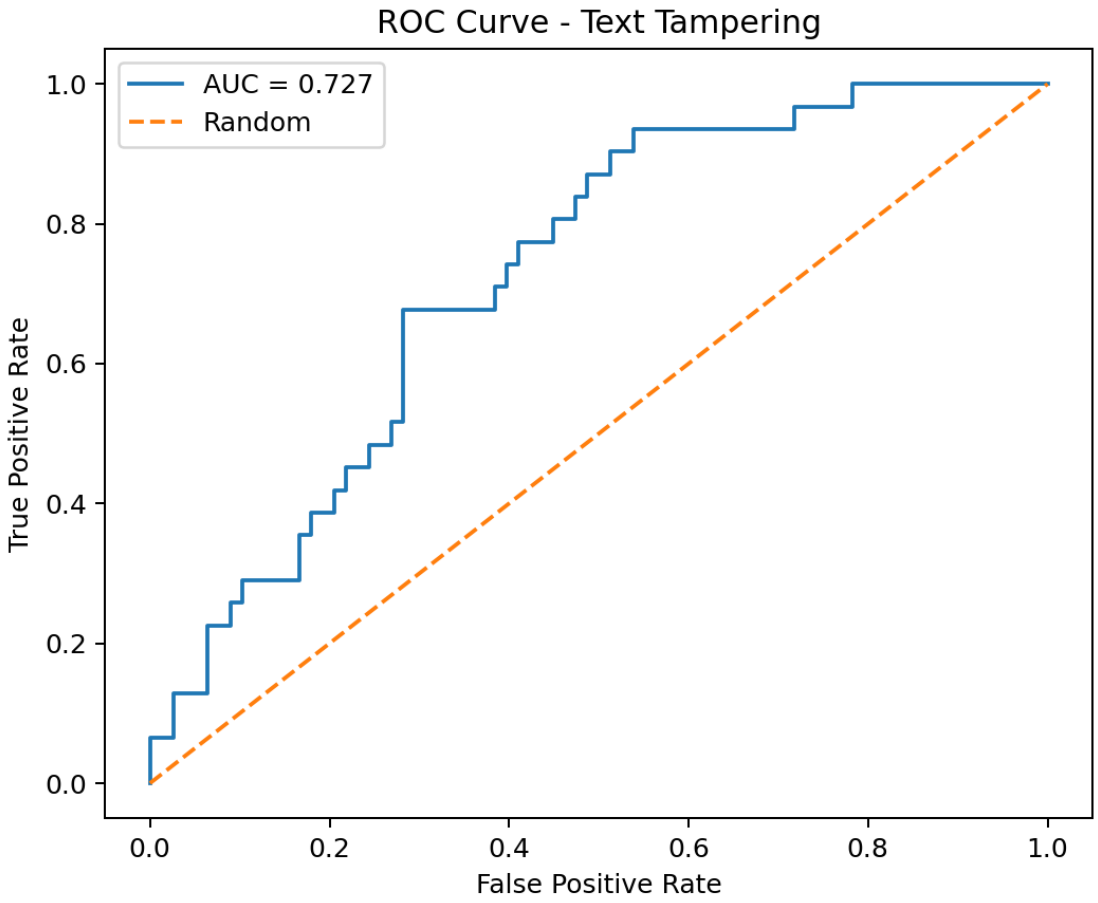
Bảng 5: Ma trận nhầm lẫn của benchmark Real/Text Tamper

Nhãn thực tế / Dự đoán	Real	Tampered
Real	55	23
Tampered	10	21

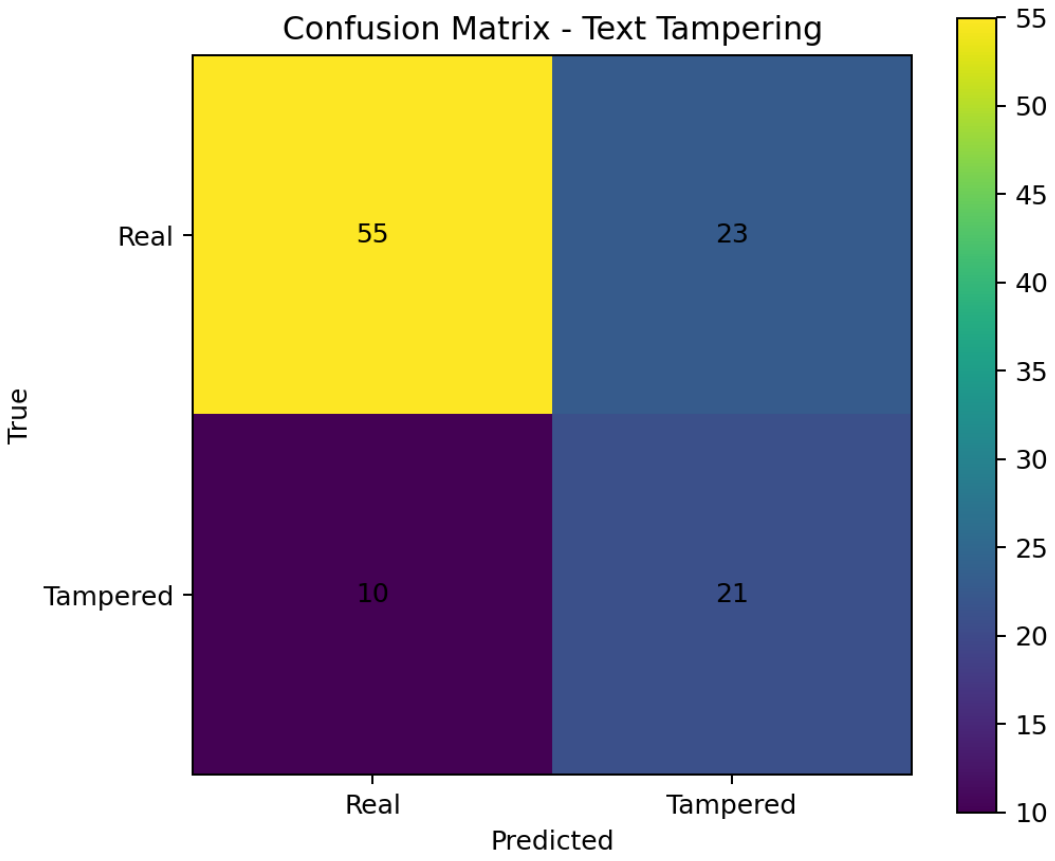
Bảng 6: Kết quả benchmark phát hiện chỉnh sửa

Chỉ số	Giá trị
Accuracy	69.72%
Precision	47.73%
Recall	67.74%
Specificity	70.51%
F1-score	56.00%
Balanced Accuracy	69.13%
AUC-ROC	72.75%

Ma trận nhầm lẫn có 23 false positive và 10 false negative. Recall 67.74% cao hơn Precision 47.73%, cho thấy benchmark bắt được nhiều mẫu Tampered nhưng vẫn cảnh báo nhầm khá nhiều ảnh Real. Các số liệu này chỉ thuộc benchmark Tuần 5.



Hình 2: Đường cong ROC của benchmark phát hiện chỉnh sửa



Hình 3: Confusion Matrix xuất từ chương trình Tuần 5

4.3 Đánh giá OCR

OCR được đánh giá bằng Character Error Rate (CER), Word Error Rate (WER) và Exact Match.

Với chuỗi chuẩn có N đơn vị:

$$CER = \frac{S_c + D_c + I_c}{N_c}, \tag{5}$$

$$WER = \frac{S_w + D_w + I_w}{N_w}. \tag{6}$$

Trong đó S, D, I lần lượt là số phép thay thế, xóa và chèn.

Benchmark OCR gồm 30 ảnh synthetic có kiểm soát. Mỗi ảnh chứa Số thửa, Tờ bản đồ và Diện tích, tương ứng 90 giá trị đối chiếu. Dữ liệu được thêm một số biến đổi nhẹ như xoay, blur và noise.

Bảng 7: Kết quả PaddleOCR trên controlled synthetic benchmark

Chỉ số	Kết quả
Số ảnh	30
Số giá trị trường	90
CER	0.00%
WER	0.00%
Exact Match	100.00%

PaddleOCR kết hợp parser đọc đúng toàn bộ 90 giá trị trong bộ synthetic này. Kết quả 100% không được suy rộng sang ảnh giấy chứng nhận thực tế.

Ghi chú về Tesseract

Tesseract chưa được chạy trên cùng bộ 30 ảnh benchmark, nên các chỉ số trong Bảng 7 chỉ thuộc PaddleOCR.

4.4 Đánh giá Geometry

Tuần 5 sử dụng 40 ảnh đường thẳng synthetic có ground truth về độ dài để kiểm tra pipeline Skeletonization + HoughLinesP.

Bảng 8: Kết quả benchmark Geometry

Chỉ số	Giá trị
Số mẫu	40
MAE	39.37 px
RMSE	70.67 px
MAPE	13.56%
Line Detection Rate	100%

Cả 40 ảnh đều có ít nhất một đoạn Hough được phát hiện. Tuy nhiên, MAE 39.37 px và RMSE 70.67 px cho thấy đoạn được chọn không phải lúc nào cũng trùng hoàn toàn với đường sinh ban đầu. Benchmark này chỉ kiểm tra đường thẳng synthetic, không phải kích thước thực của thửa đất.

5 PHẦN MỀM MINH HỌA

5.1 Môi trường

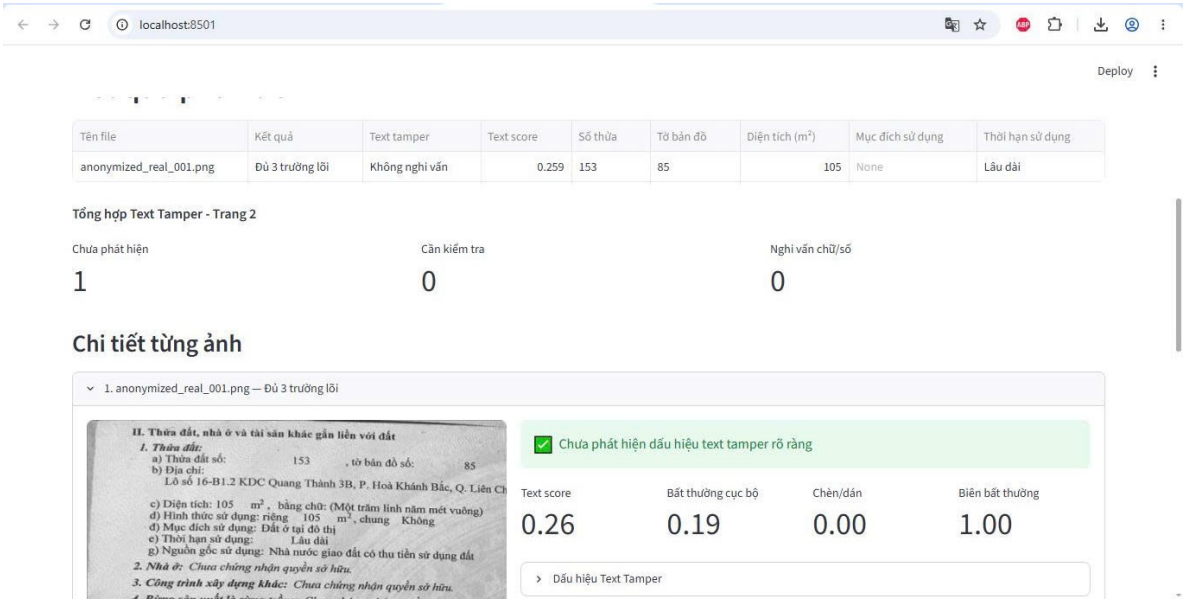
Project được kiểm thử trên Windows với Python 3.10.

Các thư viện chính gồm OpenCV, NumPy, scikit-image, scikit-learn, Pandas, PaddlePaddle, PaddleOCR và Streamlit.

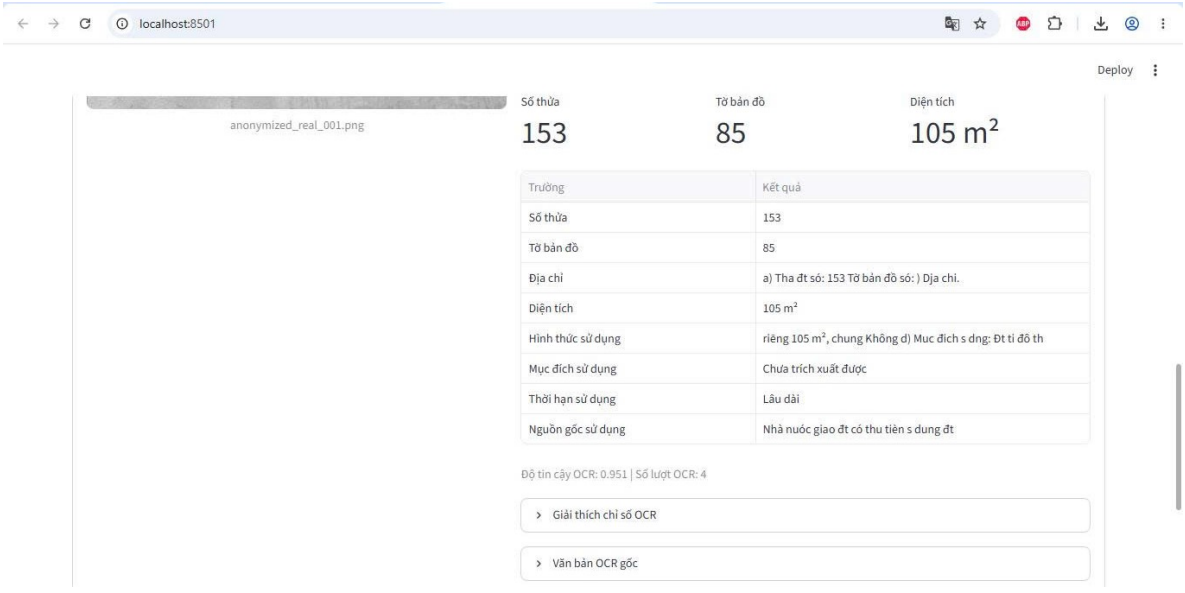
Tesseract/Pytesseract được sử dụng cho OCR baseline của Tuần 3. Streamlit được sử dụng để xây dựng giao diện demo [10].

5.2 Trang 2 – OCR và Text Tamper

Trang 2 hiển thị kết quả OCR, các trường đã trích xuất và trạng thái Text Tamper. Văn bản OCR gốc vẫn có thể mở để đối chiếu khi cần.



(a) Tổng quan kết quả phân tích Trang 2.

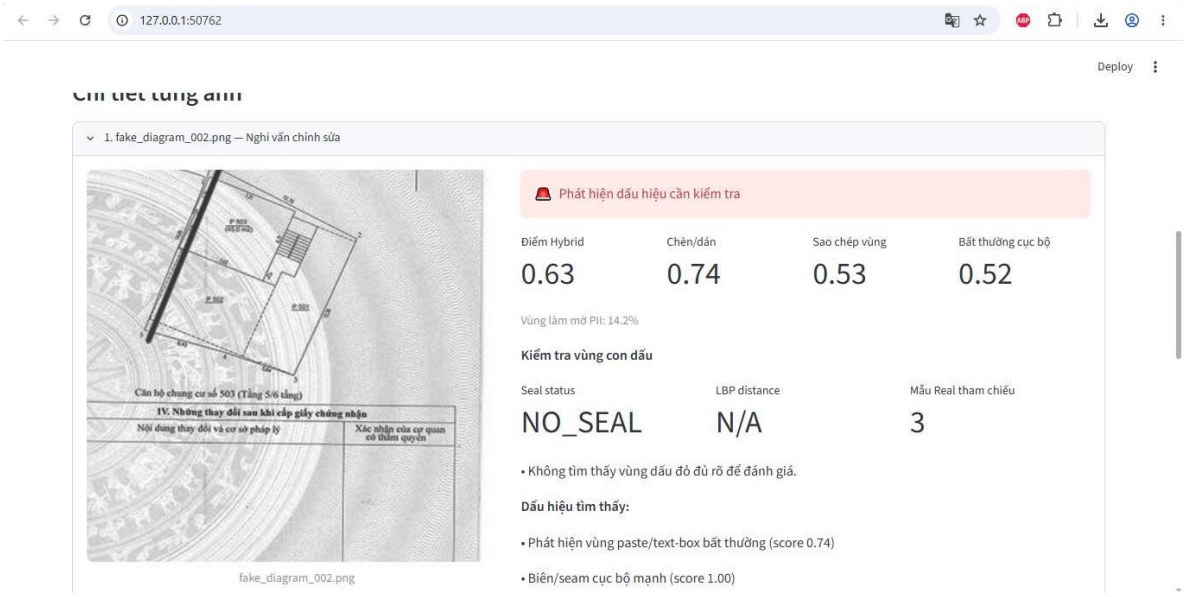


(b) Các trường thông tin được trích xuất bằng OCR.

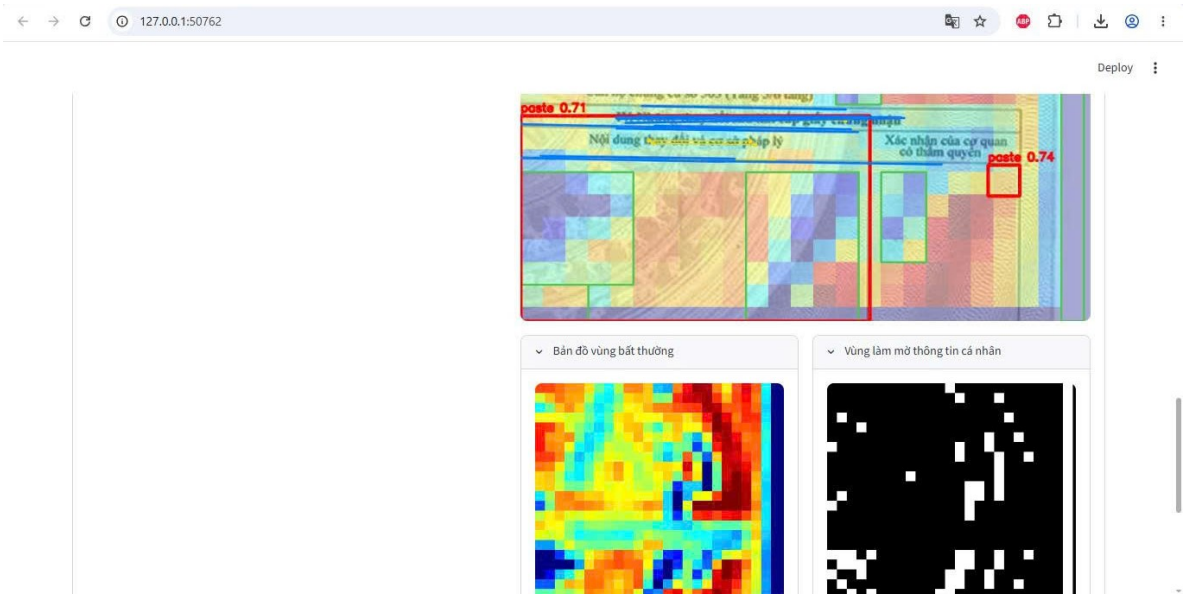
Hình 4: Kết quả OCR và Text Tamper trên Trang 2.

5.3 Trang 3 – Diagram Tamper và Seal Tamper

Trang 3 chạy hai nhánh độc lập. Diagram Tamper hiển thị Hybrid score và heatmap/vùng nghi vấn. Seal Tamper dùng HSV/LBP cùng profile Real; nếu không đủ vùng dấu hoặc mẫu tham chiếu, nhánh Seal báo thiếu dữ liệu.

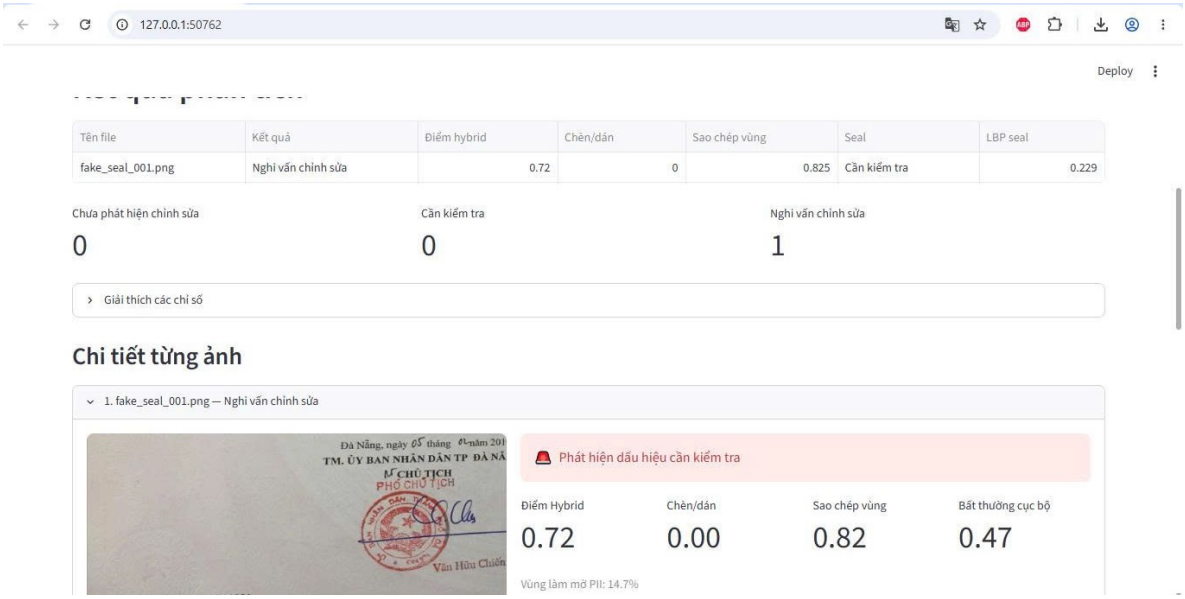


(a) Hybrid score và các thành phần của Diagram Tamper.

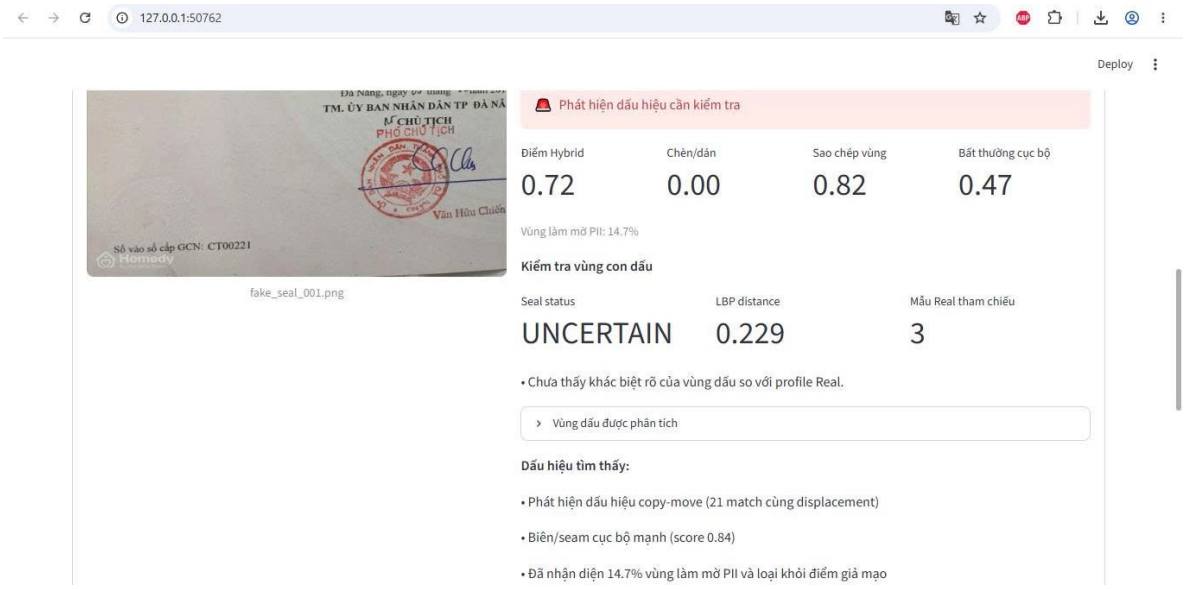


(b) Heatmap và vùng nghi vấn của Diagram Tamper.

Hình 5: Kết quả kiểm tra Diagram Tamper.



(a) Tổng quan kết quả phân tích vùng con dấu.



(b) Kết quả phân tích Seal bằng HSV/LBP và mẫu Real tham chiếu.

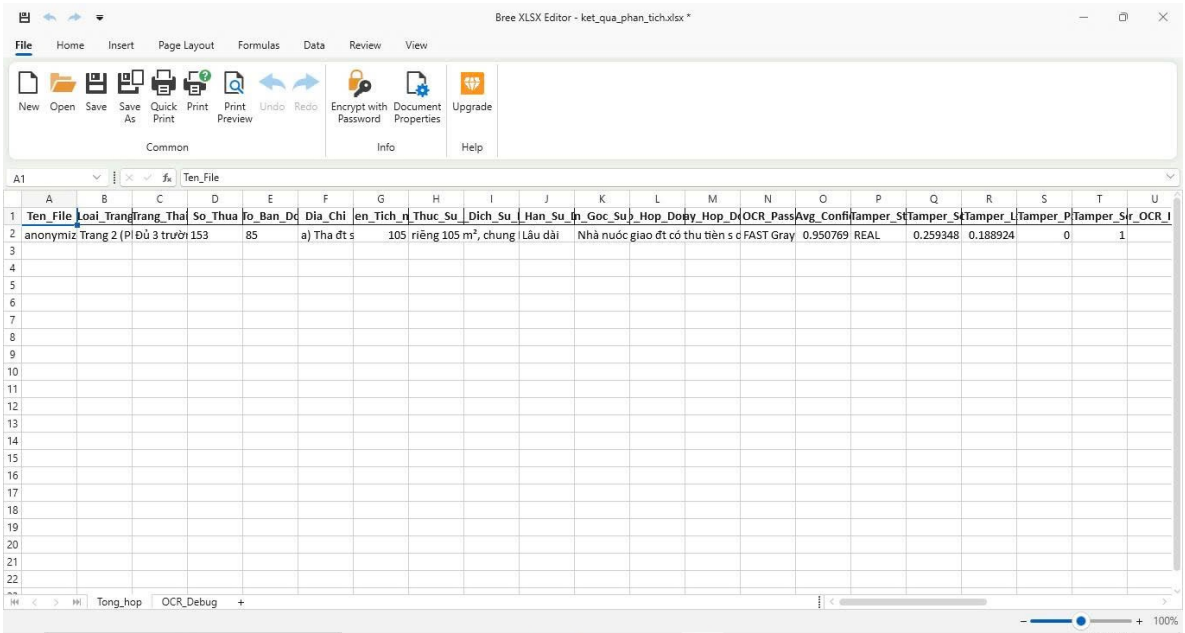
Hình 6: Kết quả kiểm tra Seal Tamper.

5.4 Batch và xuất dữ liệu

Ứng dụng hỗ trợ xử lý nhiều ảnh và chọn loại trang cho từng ảnh. Sau khi chạy, kết quả được tổng hợp trên Streamlit và có thể xuất JSON hoặc Excel.



(a) Bảng tổng hợp kết quả batch trên Streamlit.



(b) Trích đoạn tệp Excel được xuất từ chương trình.

Hình 7: Kết quả xử lý batch và xuất dữ liệu.

6 THẢO LUẬN

6.1 Hạn chế

- Chỉ có 78 ảnh nguồn độc lập; dữ liệu Tampered chủ yếu là synthetic.
- Text Tamper còn dựa trên heuristic của ba trường OCR lõi và có tín hiệu màu được thiết kế cho dữ liệu synthetic.
- Ngưỡng Text, Diagram và Seal được hiệu chỉnh trên dữ liệu hiện có, chưa có tập kiểm thử độc lập đủ lớn cho từng detector.
- Mosaic/pixelation làm thay đổi cục bộ ảnh; profile Seal cũng còn phụ thuộc số mẫu Real hiện có.
- OCR và Geometry mới được đánh giá định lượng trên benchmark synthetic có kiểm soát.

6.2 Cách diễn giải kết quả

TamperScore là chỉ số bất thường của thuật toán, không phải xác suất tài liệu giả. "Chưa phát hiện chỉnh sửa" chỉ có nghĩa detector chưa thấy đủ tín hiệu theo các tiêu chí hiện tại; các trường hợp cần kiểm tra vẫn phải được đối chiếu với ảnh và hồ sơ gốc.

7 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1 Kết luận

Đề tài đã hoàn thiện pipeline tiền xử lý, OCR, phân tích Text/Diagram/Seal Tamper và giao diện Streamlit. Các benchmark Tuần 5 cho thấy hệ thống đã chạy được đúng các thành phần đặt ra, nhưng kết quả hiện vẫn giới hạn ở quy mô dữ liệu nhỏ và phần lớn dữ liệu synthetic.

Phiên bản hiện tại phù hợp cho mục tiêu học phần và demo kỹ thuật. Để sử dụng ngoài phạm vi này cần thêm dữ liệu thực, ground truth độc lập và đánh giá riêng cho từng detector.

7.2 Hướng phát triển

- Mở rộng tập Real và bổ sung mẫu chỉnh sửa thực tế.
- Đánh giá riêng Text, Diagram và Seal Tamper trên tập kiểm thử độc lập.
- Cải thiện ROI, OCR và profile Seal trên nhiều điều kiện chụp hơn.
- Khi có đủ dữ liệu, so sánh pipeline heuristic với các mô hình học máy hoặc học sâu cho document forgery detection.

TÀI LIỆU THAM KHẢO

[1] J. Canny, "A Computational Approach to Edge Detection," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 8, no. 6, pp. 679–698, 1986.

[2] P. V. C. Hough, "Method and Means for Recognizing Complex Patterns," U.S. Patent 3,069,654, Dec. 18, 1962.

[3] T. Ojala, M. Pietikainen and T. Maenpaa, "Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns," IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 24, no. 7, pp. 971–987, 2002.

[4] J. W. Cooley and J. W. Tukey, "An Algorithm for the Machine Calculation of Complex Fourier Series," Mathematics of Computation, vol. 19, no. 90, pp. 297–301, 1965.

[5] D. G. Lowe, "Distinctive Image Features from Scale-Invariant Keypoints," International Journal of Computer Vision, vol. 60, no. 2, pp. 91–110, 2004.

[6] E. Rublee, V. Rabaud, K. Konolige and G. Bradski, "ORB: An Efficient Alternative to SIFT or SURF," in 2011 IEEE International Conference on Computer Vision, pp. 2564–2571, 2011.

[7] R. Smith, "An Overview of the Tesseract OCR Engine," in Ninth International Conference on Document Analysis and Recognition, vol. 2, pp. 629–633, 2007.

[8] OpenCV, OpenCV Documentation.
https://docs.opencv.org/
Truy cập năm 2026.

[9] PaddlePaddle, PaddleOCR Documentation and Source Code.
https://github.com/PaddlePaddle/PaddleOCR
Truy cập năm 2026.

[10] Streamlit, Streamlit Documentation.
https://docs.streamlit.io/
Truy cập năm 2026.

A CẤU TRÚC MÃ NGUỒN

Bảng 9: Các file chính của project

File	Vai trò
src/tuan1_dataset_tool_auto.py	Tạo dataset tự động, che PII và tạo synthetic tamper.
src/tuan1_dataset_tool_semi_auto.py	Công cụ hỗ trợ chọn vùng thủ công khi cần.
src/tuan2_preprocess.py	Tiền xử lý và tách ROI.
src/tuan3_baseline.py	HSV, FFT và Tesseract baseline.
src/tuan4_pipeline.py	Pipeline Geometry, OCR và Seal.
src/tuan5_evaluate.py	Đánh giá Tamper, OCR và Geometry.
src/tuan7_app.py	Ứng dụng Streamlit tích hợp cuối.

B CÁC FILE KẾT QUẢ CHÍNH

- dataset/tuan5_results/tamper_metrics.csv
- dataset/tuan5_results/tamper_predictions.csv
- dataset/tuan5_results/confusion_matrix.png
- dataset/tuan5_results/roc_curve.png
- dataset/tuan5_results/ocr_metrics.csv
- dataset/tuan5_results/ocr_details.csv
- dataset/tuan5_results/geometry_metrics.csv
- dataset/tuan5_results/geometry_details.csv